

J'ai téléchargé 5 millions de lignes de données sur la délinquance. Voici ce que j'y ai trouvé.

Le palmarès des « communes les plus cambriolées de France » à partir des données SSMSI 2024.

Par Sacha Zaouati • 5 mai 2026 • sacha.zaouati@gmail.com

Vieille-Toulouse, Haute-Garonne. 1 230 habitants. 37 cambriolages enregistrés en 2024. Taux :


67,9 ‰

CAMBRIOLAGES POUR 1 000 LOGEMENTS — VIEILLE-TOULOUSE, 2024

C'est le taux le plus élevé de France pour les communes dont le ministère de l'Intérieur publie le chiffre 2024. Si Paris connaissait le même taux, le nombre annuel de cambriolages dans la capitale serait d'environ 95 000. Le chiffre réel est de 9 235.


L'écart entre ces deux chiffres ne vient pas d'une différence de criminalité, mais d'une mécanique mathématique. Cet article la décompose.

Construction du palmarès en six étapes




LE NUAGE

10 951 communes. Chaque point représente une commune. Abscisse : population (échelle logarithmique). Ordonnée : nombre de cambriolages enregistrés en 2024 pour 1 000 logements.



VIEILLE-TOULOUSE


1 230 habitants, 37 cambriolages. Taux : 67,9 ‰. C'est le point le plus haut du jeu de données.



LE TOP 10 BRUT


Les dix communes au taux le plus élevé. 9 sur 10 ont moins de 4 000 habitants.

Boissettes (Seine-et-Marne, 437 habitants) entre dans ce classement avec 7 cambriolages enregistrés dans l'année.




LES GRANDES VILLES

Paris : 6,6 ‰. Marseille : 9,6 ‰. Lyon : 7,9 ‰. Lille : 9,5 ‰. Toulouse : 7,5 ‰.
 Bordeaux : 8,9 ‰. Toutes situées entre 6 et 10 ‰. Aucune n'apparaît dans le top 10 brut.
 La bande beige indique la zone des communes $\geq 10\,000$ habitants.



LE SEUIL

On retire les communes de moins de 10 000 habitants. Reste : 1 116 communes sur 10 951. Le seuil n'est pas mathématique. C'est un choix méthodologique inspiré des seuils utilisés dans le secteur sanitaire (300 accouchements/an pour les maternités, 50 interventions pour les centres de chirurgie cardiaque).



LE TOP 10 CORRIGÉ

Les dix communes au taux le plus élevé parmi les 1 116 retenues. 7 sur 10 sont des banlieues pavillonnaires de métropoles régionales (Tours, Bordeaux, Rouen, Rennes, Metz). 2 sont en Guyane (Kourou, Saint-Laurent-du-Maroni).

Aucune n'apparaît dans le top 10 brut.

Pourquoi un écart pareil entre les deux palmarès

Trois faits suffisent à le décrire.

**De 34 945 communes à 1 116 :
l'entonnoir méthodologique**



Sources : INSEE, SSMSI / data.gouv.fr

Sources : INSEE 2025, SSMSI / data.gouv.fr.

Fait n° 1 — Le ministère masque déjà les plus petites communes

Le SSMSI ne diffuse pas tous les chiffres communaux. Pour préserver la confidentialité, les communes où le nombre de cambriolages est trop faible pour être anonymisable sont masquées (champ est_diffuse). 10 951 communes sont diffusées, sur 34 945 communes en France selon le Code officiel géographique INSEE 2025.


Fait n° 2 — Le seuil de 10 000 est conventionnel

Il n'existe pas de seuil mathématique « vrai ». Les autorités sanitaires utilisent des seuils de fiabilité du même ordre : 300 accouchements par an minimum pour une maternité, 50 interventions par an pour un centre de chirurgie cardiaque. En dessous, les taux d'échec calculés sur trop peu de cas ne sont plus interprétables individuellement.

Fait n° 3 — Démonstration par simulation

Le scatter ci-dessous est une simulation : 1 000 communes parfaitement identiques, observées sur une année.

1 000 communes IDENTIQUES de 200 logements,
même probabilité réelle 5 ‰ — voici ce que produit le hasard




PETIT N — 200 LOGEMENTS PAR COMMUNE

Paramètres : 1 000 communes simulées, 200 logements chacune, probabilité réelle qu'un logement soit cambriolé fixée à 5 ‰ (moyenne nationale). Pour chaque commune, on tire un nombre de cambriolages selon une loi de Poisson($\lambda = n \times p$) = Poisson(1).

Résultats : 392 communes à 0 cambriolage. 84 communes à un taux ≥ 15 ‰. Maximum observé : 25 ‰.

Toutes ces communes sont identiques en réalité. La dispersion observée vient uniquement du tirage aléatoire.

Mêmes 1 000 communes, mais cette fois 50 000 logements chacune
Le hasard se tasse autour de la vraie valeur



GRAND N — 50 000 LOGEMENTS PAR COMMUNE

Mêmes 1 000 communes, même probabilité réelle de 5 ‰, mais 50 000 logements chacune. Tous les taux observés tombent entre 4,2 et 6,0 ‰.

L'écart-type théorique passe de 5,0 ‰ à 0,32 ‰ entre les deux simulations.

L'écart-type d'un taux observé

$$\sigma_{\text{taux}} \approx \sqrt{\frac{p}{n}}$$

p = probabilité réelle qu'un logement soit cambriolé

n = nombre de logements de la commune

σ = écart-type du taux observé une année donnée

Pour Boissettes ($n \approx 200$) : $\sigma \approx 5$ ‰
Pour Paris ($n \approx 1\,400\,000$) : $\sigma \approx 0,07$ ‰

L'écart-type du taux observé décroît en $1/\sqrt{n}$. Pour Boissettes ($n \approx 200$ logements), $\sigma \approx 5$ ‰. Pour Paris ($n \approx 1\,400\,000$ logements), $\sigma \approx 0,07$ ‰. Le rapport est d'environ 70.

Régression vers la moyenne

Conséquence directe du fait n° 3 : les communes qui apparaissent dans le top brut une année donnée ont une faible probabilité d'y figurer l'année suivante. Sur les 10 communes du top brut 2024, on peut prédire que la majorité aura disparu du top 100 en 2025. Cette prédiction sera vérifiable et vérifiée en mai 2027, à la publication de la base SSMSI 2025.

Sources et code

Toutes les données viennent de la base communale SSMSI 2024 publiée sur data.gouv.fr en février 2026. L'analyse a été faite en R (Quarto) et est entièrement reproductible. Les scripts qui génèrent les graphiques sont également disponibles dans le dépôt GitHub.

DEMAIN — ÉPISODE 2

Les lycées « à 100 % de réussite » au bac

Le mythe du lycée parfait repose presque toujours sur des classes de moins de trente élèves. Même mécanique mathématique que ci-dessus.

NOTE MÉTHODOLOGIQUE

Source. SSMSI, base communale 2025 publiée en février 2026 sur data.gouv.fr, indicateur « Cambriolages de logement », année 2024. Le taux est calculé par 1 000 logements, à partir du recensement INSEE.

Périmètre. 10 951 communes diffusées sur 34 945 communes françaises (INSEE 2025).

Simulation. Tirages indépendants de Poisson($\lambda = n \times p$), avec n = nombre de logements, $p = 0,005$ (taux moyen national). Graine fixée à 42.

Reproductibilité. Code (R + Quarto + scripts ggplot2) et données extraites : github.com/sachazaouati/illusion-petits-nombres. Code MIT, articles et graphiques CC BY 4.0.